

Adversariale Attacken im Machine Learning - eine Systematisierung

Harry Lohr
Fachhochschule Südwestfalen

Konferenzseminar Machine Learning
Wintersemester 2025/26

Abstract—Adversariale Angriffe offenbaren grundlegende Schwächen moderner KI-Systeme, da bereits minimale böswillige Manipulationen zu gravierenden Folgen führen können. Diese Survey-Arbeit bietet eine systematisierte Übersicht zentraler Angriffstypen entlang des KI-Lebenszyklus samt gängiger Verteidigungsstrategien. Angelehnt an den *NIST Trustworthy and Responsible AI report* vom März 2025 können Angriffe auf prädiktive und generative Modelle unterschieden werden. In dieser Arbeit wird auf data poisoning, backdoor poisoning, evasive Attacks sowie Prompt-Injektionen näher eingegangen. Ein Praxisteil demonstriert anhand eines Bildklassifikators die Auswirkungen von data- und backdoor-poisoning-Angriffen, um einen Realitätsbezug greifbarer zu machen und, als Mehrwert dieser Arbeit, um über einen alleinigen theoretischen Querschnitt hinauszugehen. Angesichts des rasanten Forschungsfortschritts und zahlreicher Angriffstechniken stehen KI-Systeme vor wachsenden Herausforderungen. Trotz vielfältiger Schutzmaßnahmen bestehen theoretische Grenzen der Robustheit, weshalb dringend standardisierte Evaluationstools zur Prüfung auf Schwachstellen erforderlich sind, um Sicherheit, Zuverlässigkeit und Akzeptanz vertrauenswürdiger KI zu erhöhen.

Keywords: Adversariale Angriffs- und Verteidigungsstrategien, Systematisierung, data poisoning, backdoor poisoning, Prompt-Injection-Angriffe, Robustheit

I. EINLEITUNG

Spätestens seit ChatGPT der Öffentlichkeit vorgestellt wurde, wird eine lebhafte Diskussion darüber geführt, welche Auswirkungen die Nutzung von Künstlicher Intelligenz hat. Unbestritten ist, dass KI-Tools längst Einzug in unseren Alltag gehalten haben, obwohl sie laut einer 2023 durchgeführten globalen Studie der University of Queensland (Australien) längst noch nicht so euphorisch gesehen werden, s. [1].

In Anlehnung an einen von John F. Kennedy getätigten Ausspruch fragt The Guardian „Don’t ask what AI can do for us, ask what it is doing to us”: are ChatGPT and co harming human intelligence? [2] Studien wie die des Massachusetts Institute of Technology legen dies nahe [3][4]. Zweifelsfrei jedoch hat KI in vielen Bereichen Fortschritte gebracht. Stellvertretend genannt sei die medizinische Diagnostik. Dennoch lauern zahlreiche Gefahren auf die KI-Systeme. Unbeabsichtigte Risiken resultieren aus unerwünschten (Umwelt-)Einflüssen bspw. auf Sensoren, einer unzureichenden Akribie im Umgang mit Datensätzen u.v.m.

Diese Arbeit beschränkt sich auf Bedrohungen, die aus böswilliger Intention heraus die Verfügbarkeit, Vertraulichkeit und Integrität dieser Systeme kompromittieren wollen. Wie sich zeigt, können selbst leistungsfähige KI-Systeme durch kleinste Manipulationen in die Irre geführt werden mit schwerwiegenden Folgen. Manipulierte Röntgenbilder können bei der Patientenbehandlung zu Fehldiagnosen führen, da z.B. „signs of disease can be removed“ [Seite 2 bei 5]. Beim autonomen Fahren gilt es „to detect and recognize traffic signs and cars accurately [...] to make safe and efficient decisions“ [Seite 1 bei 6]. Zugangssysteme, die biometrische Faktoren wie bei der Gesichtserkennung nutzen, sollten so robust sein, dass „security breaches, unauthorized access, and privacy violation“ [Seite 4 bei 7] vermieden werden. Fehlt es an Robustheit, entsteht Misstrauen um die Zuverlässigkeit solcher Systeme in kritischen Umgebungen, infolgedessen sind ein tiefgehendes Verständnis über mögliche Angriffsarten sowie ihre Auswirkungen von wachsender Bedeutung.

Ziel dieser Arbeit ist die Systematisierung geläufiger Angriffs- und Verteidigungsstrategien. Kapitel 2 hebt eine besonders gelungene Arbeit zu dieser Idee heraus. Kapitel 3 führt in den Begriff des adversarial machine learning ein und stellt eine maßgebliche Publikation auf diesem Forschungsfeld vor. Es wird gezeigt, dass Angreifer an mehreren Stellen des KI-Lebenszyklus ansetzen können und wie sie sich strategisch in Stellung bringen. Kapitel 4 und 5 beleuchten getrennt Angriffs- und Verteidigungsmethoden. Rankings der besten Strategien werden nicht vorgenommen, dazu unterscheiden sich KI-Systeme und die dazu passenden Szenarien zu stark. Kapitel 6 widmet sich der Simulation von poisoning-Angriffen, damit es nicht nur bei einer theoretischen Betrachtung bleibt. Eine kritische Reflektion sowie eine Vorstellung aktueller Forschungsfragen schließt sich in Kapitel 7 an. Das Fazit in Kapitel 8 rundet diese Arbeit ab.

II. VERWANDTE ARBEITEN

In zahlreichen Arbeiten finden sich Klassifikationen, sei es aus der Perspektive der Cybersicherheit im Allgemeinen [8], speziell für Domänen wie computer vision bei [9] oder [10], oder für bestimmte machine-learning-Ansätze wie regression learning [11], wo spezifisch zugeschnittene

Angriffs- und Abwehrszenarios aufgezeigt werden. Teils sind Systematisierungen thematisch zu eng gefasst, nicht strukturiert genug oder mittlerweile überholt, da sich dieses Feld rasant weiterentwickelt. Der im März 2025 erschienene *NIST Trustworthy and Responsible AI report* [12] versucht den aktuellen Forschungsstand aus **Angriffersicht hinsichtlich seiner Zielsetzung** zusammenzufassen und sticht durch eine unterstützende visuelle Klassifikation der Methoden heraus. Diese Arbeit lehnt sich in weiten Teilen daran an.

III. ADVERSARIAL MACHINE LEARNING - BEGRIFFSURSPRUNG UND SCHWACHSTELLEN IM KI-LEBENSZYKLUS

„Adversarial Machine Learning (AML) is the use of malicious inputs to attack and fool Machine Learning (ML) models into taking the wrong actions“ [Seite 36 bei 13]. Der Name *adversarial* entstammt der Arbeit [14] einer Gruppe um Ian Goodfellow, dem “Miterfinder“ der Generative Adversarial Networks (GANs). In der bezeichneten Publikation brachte man ursprünglich zur Klassifizierung des MNIST-Datensatzes verwendete KI-Modelle dazu, von Originalbildern täuschend echt „visually hard to distinguish, adversarial examples“ [Seite 5 bei 14] falsch zu klassifizieren. Man erreichte dies „by applying a certain hardly perceptible perturbation“ [Seite 1 bei 14]. Es war verblüffend, das state-of-the-art-Modelle derartig anfällig waren. In einer weiteren Arbeit [15] gingen Goodfellow/Shlens/Szegedy den Ursachen der Angreifbarkeit weiter nach. Zwischen diesen beiden Beiträgen erschien die wegweisende Studie um die Generative Adversarial Networks [16], wobei es seinerzeit im Kern darum ging, sich von einem Generator (ein eigenständiges neuronales Netz) täuschend echte fake-Bilder generieren zu lassen und sie einem Discriminator (ein weiteres eigenständiges neuronales Netz, daher die Mehrzahl bei GANs) mit dem Ziel vorzulegen, dass sie im Rahmen einer Bild-Klassifikation nicht mehr als *fake* erkannt werden. GANs konnten die Erstellung benötigter *adversarial examples* rund um die damalige Forschungsarbeit beschleunigen, s. hierzu einen diesbezüglichen Vortrag Goodfellows [17].

Ging es 2014 bei der Entdeckung der Anfälligkeit von KI-Modellen noch explizit um Bildklassifikation, so reicht heutzutage das Bedrohungsszenario weit über Bilder hinaus bis hin zu Texten, Audio, Video usw., s. [Seite 9 bei 12]. Wie die nachfolgende Abbildung 3.1 [entnommen von Seite 198 bei 18] verdeutlicht, versuchen Angreifer mittlerweile unterschiedlichste potenzielle Ansatzpunkte und Schwachstellen zu jeder Phase im KI-Lebenszyklus auszunutzen. Auf den ersten Blick erscheint selbst ein in sich *abgeschlossenes* System sicher zu sein, aber die Forschung zeigt für die Praxis Wege auf, wie trotzdem Angriffe stattfinden können. Vortrainierte Modelle könnten kompromittiert sein u.v.m. Auf der anderen Seite kommen zum Schutz raffinierte Verteidigungspraktiken zum Einsatz. Beide Handlungsstoßrichtungen werden in den nachfolgenden zwei Kapiteln ausführlich dargestellt.




Abbildung 3-1: Lebenszyklus eines KI-Systems

In Abb. 3.1 sind fünf Stadien im Lebenszyklus aufgeführt, bei anderen wie [19] sind es sieben, welches jedoch für die weitere Betrachtung keine Rolle spielt. Die Strategie eines Angreifers leitet sich nun wie folgt ab, wobei die nachfolgende Abb. 3-2 [entn. Seite 152 bei 18, untere Bildpartie fehlt] das Zusammenspiel der vier Faktoren sehr greifbar illustriert:

- 1) Welcher Zweck wird mit dem Angriff verfolgt? („*goal*“)
- 2) Wissen über anzugreifendes Modell/seine Architektur? („*knowledge*“)
- 3) Fokus und Befähigung des Angreifers auf welche Phase? („*capabilities*“)
- 4) Welche Werkzeuge kommen zur Anwendung? („*type*“)




Abbildung 3-2: Strategische Faktoren für Angreifer

Gründe des Angreifers können u.a. sein, die Integrität oder Verfügbarkeit von KI-Systemen in Mitleidenschaft ziehen zu wollen. Wie gut kennt ein Angreifer sein Ziel? Bei **white-box**-Angriffen verfügt er über vollständiges detailliertes Wissen zu Trainingsdaten, dem Modellaufbau und den Parametern.

Ein **black-box**-Angriff bedeutet, dass ihm sehr geringes oder kein Wissen vorliegt. Bei **gray-box**-Angriffen gibt es lediglich lückenhaftes Wissen. Abschließend gilt zu entscheiden, an welchem Punkt er mit welchem Werkzeug ansetzt.

Wir haben zur Historie des adversarial machine learning und in die bedeutenden Studien von Ian Goodfellow Einblicke gewonnen. Längst nicht mehr konzentriert sich das Forschungsgebiet auf Bilder. Aufgrund der Komplexität der KI-Systeme erwachsen zahlreiche potenzielle Schwachstellen, für die je nach Wissen und Zweck eines Angriffs entsprechende Werkzeuge ausgewählt werden. Die Verteidigung versucht sich ihrerseits in Stellung zu bringen. In Kapitel 4 fahren wir mit den Angriffsstrategien fort.

IV. ÜBERSICHT/KLASSIFIKATION DER ANGRIFFSMETHODEN

Im Laufe der Zeit ist eine Bandbreite an Machine-Learning-Modellen entstanden, die sich nach unterschiedlichsten Kriterien einteilen lassen wie z.B. eine Einordnung auf „überwachtes, unüberwachtes, teilüberwachtes, selbstüberwachtes Lernen“ [Seite 37 bei 20]. Es ließe sich vielleicht danach unterscheiden, ob ein Modell „trainiert und anschließend in einer Produktivumgebung eingesetzt [wird], wo es ohne weiteres Lernen läuft“ [Seite 46 bei 20] oder ob kontinuierliches Lernen in einer real-time-Umgebung erfolgt. Der Gedanke dahinter ist klar: jede Modell-Architektur weist aufgrund ihres Designs ggf. eine oder mehrere Angriffsflächen auf, die auch auf andere Architekturen übertragbar oder für einen bestimmten Fall gar nur einzigartig sind. Immer vor dem Hintergrund welcher Grad an Information einem Angreifer über ein KI-System zur Verfügung steht (*white/gray/black*) und welchen Zweck er mit einem Angriff verfolgt, muss dieser sich beim Griff in den “Werkzeugkasten” sehr genau überlegen, welche Angriffsstrategie(n) geeignet ist/sind und ob man seine Ziele auf direktem oder indirektem Wege erreichen kann.

Neben den klassischen Modellen, wo es häufig wie beim Bildklassifikator darum geht auf der Basis von Eingabedaten eine Vorhersage zu treffen (**prädiktive KI**), gewinnt seit einigen Jahren generative KI mit der Erzeugung völlig neuer Inhalte zunehmend an Terrain. Wir halten uns bei der Abhandlung ausgewählter Angriffsszenarien an diese bei [12] getroffene Abgrenzung. Nachfolgende Abbildung 4.1 [entnommen Seite 35 bei 12] soll eine Einordnung auf Seiten **generativer KI-Modelle** erleichtern, in dem sie für die ausgewählten Ziele Verfügbarkeit, Integrität, Privacy und Missbrauch entsprechende Angriffsflächen aufführt samt dazugehöriger Angriffsmethoden. Das visuelle Pendant für prädiktive Modelle findet sich im Anhang. Ein Vergleich dieser Taxonomien legt schlüssig dar, dass gewisse Strategien wie model oder data poisoning, auf die wir gleich näher eingehen, in beiden Modellwelten Anwendung finden und dass gerade der bei generativen Modellen so herausragende Prompt ein dankbar angenommenes Einfallstor für Angriffe darstellt:




Abbildung 4-1: Klassifikation für generative KI

Ein direkter Zugriff auf Trainingsdaten oder Modellparameter reduziert das Hindernis für Angreifer. Aus diesem Grunde sind data und model poisoning klassische Angriffsansätze. **Data poisoning** bedeutet, „an adversary injects malicious data into training datasets to manipulate model behavior, leading to incorrect predictions or biases“ [Seite 11 bei 18]. Beim **model poisoning** wird bezweckt, „...[to] manipulate the model to degrade performance or introduce biases“ [Seite 140 bei 18]. Obwohl der Zugriff auf Trainings- & Modelldaten fraglos bei white-box-Angriffen am einfachsten ist, sind in der Literatur auch erfolgreiche black- & gray-box-Ansätze bekannt, s. Seite 19 bei 12. Eine poisoning-Variante ist die des **backdoor poisoning**, vorgestellt von [21]. Im konkreten Fall ging es um „creating a U.S. street sign classifier that identifies stop signs as speed limits when a special sticker is added to the stop sign“ [Seite 1 bei 21]. Der Klassifikator lernt den Trigger, hier einen Sticker, mit einem bestimmten Ziellabel zu assoziieren, so dass wann immer der Klassifikator den eingebauten Trigger erkennt, er entsprechend den Vorgaben der Angreifer handelt, ansonsten unter regulären Umständen gemäß seiner vorbestimmten Aufgabe arbeitet und sogar (unverdächtige) „state-of-the-art performance on the user’s training and validation sample“ [Seite 1 bei 21] erreicht. Die Gefahr lauert den Autoren der Studie zufolge darin, dass das Training eines Modells mangels eigener Rechenleistung an (nicht vertrauenswürdige) Dritte ausgelagert wird oder man sich zum Feintuning an (ggf. manipulierten) vortrainierten Modellen bedient. Anhand der Ziffer 1 vom MNIST-Datensatz sei in Abbildung 4-2 [entn. S. 6 bei 21] der Einbau einfacher Trigger angedeutet:




Abbildung 4-2: MNIST-trigger für backdoor poisoning

Wenn ein Angreifer in prädiktiven KI-Systemen keinen Zugriff auf die Trainingsdaten erlangt, bleibt ihm u.a. der **evasion**-Ansatz, um Vorhersagen des Modells zu seinen Gunsten zu steuern. „Evasion attacks modify testing samples to create adversarial example, which are similar to the original sample (e.g., according to certain distance metrics) but alter the model predictions to the attacker’s choices“ [Seite 6 bei 12]. Die von Goodfellow in Kapitel 2 gemachte Entdeckung ist dem evasion-Ansatz zuzurechnen.

Auf Seiten generativer KI verdient der allgegenwärtige Prompt besondere Beachtung. Bei **direct prompt injection** „malicious instructions are embedded directly within the user’s input to an AI system“ [Seite 4 bei 22]. Auf diese Weise können böswillige Systemkommandos ausgelöst werden. Ungeschützte Sprachmodelle lassen sich bspw. schon zu einem Fehlverhalten bewegen, wenn Angreifer ihrem gewünschten Anweisungen im Prompt einen Satz voranstellen wie „ignore all previous instructions and...“ [Seite 4 bei 22]. Angreifer benötigen jedoch nicht unbedingt direkten Zugriff auf den Prompt, gerade dann, wenn diese Modelle robust gemacht sind gegen direkte Attacken. Es wurden Methoden entwickelt unter dem Oberbegriff **indirect prompt injection**. Eine Variante davon ist die *web content injection*. „Malicious instructions are embedded in web pages that AI agents browse“ [Seite 4 bei 22]. Diese versteckten Hinweise führen zu zahlreichen unerwünschten Folgen wie dem Überschreiben der Vorgaben für den Prompt (*prompt constraint*) oder dem Einlesen von JavaScript. [Seiten 22 bis 29 bei 23] beschreibt unterschiedlichste Szenarien bei der *web content injection* samt einer Risikoeinschätzung von critical bis low. [22] trägt mit einem Klassifizierungsschema insgesamt zum Verständnis von *prompt injection* in all seinen Spielarten bei.

Es gibt eine Vielzahl an Methoden, entwickelt je nach Einfallsstelle und unter Beachtung der Angreifern zur Verfügung stehenden Informationen. Manche davon passen nicht nur auf eine bestimmte Architektur, sondern „adversarial perturbations are able to transfer among different model structure“ [Seite 153 bei 24]. Geht es Angreifern gezielt darum, dass Modelle wie beim evasion-Ansatz im Rahmen der Bildklassifikation bestimmte falsche Klassen vorhersagen, dann spricht man auch von **targeted attack**. Anderen Methoden kommt es bloß darauf an, dass Modelle unabhängig vom Ansatz falsche Entscheidungen treffen. In diesem Fall spricht man von **untargeted attack**. Es geht in Kapitel 5 weiter mit den Verteidigungsstrategien.

V. ÜBERSICHT/KLASSIFIKATION DER VERTEIDIGUNGSMETHODEN

Robustheit gegen adversariale Angriffe ist besonders in sicherheitskritischen KI-Systemen von höchster Bedeutung. Zum Schutz gilt es „to either detect and counteract adversarial inputs (**reactive defenses**) or fortify the models against potential attacks during training (**proactive defenses**)“ [Seite

159 bei 18]. [Seite 161 bei 18] katalogisiert eine Reihe von Verteidigungsstrategien, welche u.a. auch zur Wahrung der privacy und zur Sicherheit während des Deployments entwickelt worden sind, auf die wir im vorherigen Kapitel nicht eingingen. Zur Wahrung einer einheitlichen Linie soll in nachfolgender Tabelle 5-1 exemplarisch einzig für die bisher näher beschriebenen Angriffsmethoden (*data / model / backdoor poisoning, evasive attack, (in)direct prompt injection*) eine kleine Auswahl möglicher Schutzmechanismen vorgestellt werden, die sich entsprechend den pro- oder reactive-Strategien zuordnen lassen:

Angriffsart	Typus	Verteidigungsmechanismen (Auswahl)	Beschreibung/Beispiele
Data Poisoning	proaktiv	Datenherkunft und Integrität prüfen	vertrauenswürdige Quellen
	proaktiv	Datenbereinigung / Filtern vor dem Training	Erkennen & Löschen verdächtiger Daten
	proaktiv	Zugriffskontrolle auf Trainingsdaten	„add, edit, or label training data“-Rechte
	proaktiv	adversarial (poisoning) training	Einbeziehung simulierter „poisoned“-Datensätze
Model Poisoning	proaktiv	Robuste Initialisierung	Mehrfachtraining (Ensembles), Modellvergleich
	reaktiv	Anomalie-Erkennung in Modellupdates	z.B. Abweichungen typischer Gradientenmuster
	proaktiv	Zugriffskontrolle	wer darf Modellparameter bearbeiten?
	proaktiv	Client Reputation (bei föderiertem Lernen)	Vermeidung schädlicher Updates
Backdoor Poisoning	proaktiv	Datenherkunft und Integrität prüfen	vertrauenswürdige Quellen
	proaktiv	Identifikation potenzieller Trigger	z.B. Check auf versteckte/spezifische Inputmuster
	reaktiv	Backdoor Unlearning, Nachtrainieren	„model surgery“ um Trigger zu „vergessen“
Evasive Attack	proaktiv	Robuste Daten-Validierung inkl. -herkunft	Quellen-Authentifizierung, „provenance tracking“
	proaktiv	Prüfung der Datenbereiche auf Sicherheit	z.B. DeepSafe [25] für Bilder
	reaktiv	Modell-Überwachung & drift detection	Hinweise auf versteckte poisoning-Effekte
Prompt Injection (Direct/ Indirect)	proaktiv	Eingabebereinigung vor der Verarbeitung	z.B. um Meta-Instruktionen, Codeblöcke
	proaktiv	Klassifikation nach „trusted/untrusted“	Betrifft Systemanweisungen & Nutzereingaben
	proaktiv	Ausgabvalidierung / Post-Processing	z.B. Ausführung unerwünschter Befehle verhindern
	reaktiv	Kontinuierliches Monitoring, Tests	simulierte Angriffe, Anomalie-Erkennung, Logging

Tabelle 5-1: Taxonomie ausgewählter Schutzmechanismen

Die Prüfung der Datenherkunft oder -bereinigung vor Trainingsbeginn ist grundsätzlich zum Schutz vor data poisoning von sehr hoher Bedeutung. Gegen evasive Angriffe kann helfen die Performance seines Modells im Zeitablauf im Fokus zu behalten. Sich häufende Fehler etwa bei der biometrischen Gesichtserkennung verlangen ggf. nach einer drift detection, also dem Erkennen von Leistungsabfällen. Bei Prompteingaben wiederum ist zwingend dafür zu sorgen, dass sie vor der Verarbeitung um potenziell schädliche Anweisungen oder Codeblöcke bereinigt werden. Unabdingbar ist im Kern gegen jedweden Angriff das Zusammenspiel mehrerer Verteidigungsmechanismen.

Im Geschäftsleben spielt fast immer der Aspekt der Wirtschaftlichkeit eine Rolle. Es gibt Investitionen in Sicherheit, die „rein wirtschaftlich betrachtet nicht sinnvoll sind und dennoch durchgeführt werden, wie zum Beispiel als gesetzliche Notwendigkeit“ [Seite 643 bei 26]. Das Feld des „Return on Security Investment“ [Seite 636 bei 26] und der Aspekt der Wirtschaftlichkeit sollen hier außer acht gelassen werden, nichtsdestotrotz gibt es regelmäßig ein Spannungsfeld (englisch „tradeoff“), die den Entscheidungen pro oder contra einer Umsetzung von Sicherheitsmaßnahmen innewohnen. Bei der Abwehr von Angriffen geht es darum, „between the benefit of a correct attack detection and the cost of a false alarm“ [Seite 60 bei 27] auszubalancieren. So kann leicht vorstellbar ein „Übermaß an Warnungen [...] zu Ermüdungserscheinungen führen: Sie [als KI-

Systemverantwortliche] werden desensibilisiert und übersehen oder ignorieren wichtige Warnungen einfach“ [Seite 380 bei 28]. Nicht unerwähnt sollte bleiben, dass natürlich auch ein Angreifer immer ausloten muss, welchen potenziellen Nutzen einem (anfangs in der Größe unbekannten) Aufwand gegenübersteht. Somit begegnet auch er einem tradeoff.

Dies führt zur Frage, ob und wie sich die Effektivität der Verteidigungsmechanismen messen lässt. Im Bereich des autonomen Fahrens (ADS) gibt es die Arbeit um den RobustBench [29]. Leider fehlt es noch an weiteren Forschungen in diesem speziellen Fachgebiet, denn „good performance on our benchmark does not guarantee the safety of the benchmarked model in a real-world deployment“ [Seite 10 bei 29]. Und „While benchmarks like RobustBench exist for general adversarial robustness in computer vision, real-world ADS benchmarks are lacking“ [Seite 191 bei 18]. Ein paar bei [Seite 54 bei 12] aufgeführte Benchmarks prüfen KI-Systeme jedenfalls schon u.a. auf Robustheit.

Die Verteidigung steht den zahlreichen Angriffsmethoden nicht unbewaffnet gegenüber. Es wird zwischen reaktiven und proaktiven Methoden unterschieden, wobei empfohlen ist im Rahmen einer „what-if analysis [...] potential attack scenarios“ [Seite 9 bei 27] zu simulieren und durchzuspielen, damit man Klarheit darüber gewinnt, gegen welche Bedrohungen sein eigenes KI-System zu schützen ist. Doch selbst wenn Schutzmaßnahmen gegen bekannte Risiken wirken, so ist deren Wirksamkeit „determined not just by how well it will defend against existing attack, but also how well it defends against unforeseen attacks“ [Seite 57 bei 12]. Kapitel 6 simuliert nun Angriffe auf einen Bildklassifikator.

VI. PRAXISFALL - POISONING

Anhand eines trivialen Beispiels wird illustriert, welche gravierenden Folgen es haben kann, wenn Datensätze ungeprüft in einen Trainingssatz aufgenommen und somit bspw. data oder backdoor poisoning in irgendeiner Form zugelassen wird. Für den „human-face-emotions“-Datensatz [30] wird ein Bildklassifikator hinsichtlich seiner fünf Emotionen (*angry*, *fear*, *happy*, *sad* und *surprise*) erstellt. Der Datensatz ist relativ unausgewogen, da fast ein Drittel aller knapp 58.000 Bilder unter die Kategorie *happy* fallen, und *surprise* mit knapp 14% weit unter dem rechnerischen Durchschnittsanteil von 20% liegt. Aus diesem Grund balancieren wir den zum Training und Testen verwendeten Datenauszug mit je 8.000 Bildern pro Emotion aus und verwenden ein Keras-Sequential-Modell, welches im Aufbau in weiten Teilen dem bei [31] ähnelt. Statt eines Adam- wird der SGD-Optimizer genutzt. Der Code ist einzusehen unter https://github.com/hlohr/konferenzseminar_kapitel_6_data_poisoning.git.

Der Testdatensatz erreicht eine accuracy von **61.9%**, die den bei [31] und [32] vorgestellten Ergebnissen, ebenfalls aus

der „emotion detection“, relativ nahe kommt. Auf Feintuning und die Suche nach den besten Hyperparametern wird verzichtet, da es an dieser Stelle nicht Demonstrationszweck ist, die Modellgenauigkeit weiter zu steigern.

a) data poisoning:

Je 1.000 der 8.000 Label pro Emotion werden bewusst gefälscht. 12.5% der 40.000 Label sind somit nicht mehr korrekt. Der Testdatensatz erreicht nur noch eine accuracy von **51.2%**. Es wurde beträchtlich an Genauigkeit eingebüßt und es ist naheliegend, dass die Genauigkeit eines Bildklassifikators je nach Grad und Umsetzung des data poisoning variiert.

b) backdoor-poisoning:

Jeder Emotion werden 500 Bilder entnommen. In jedes der in Summe 2.500 Bilder (48x48 Pixel) wird zentral ein 3x3 großes Quadrat mit Pixelwert 0 in der Mitte sowie Pixelwert 128 als Umrandung eingefügt, welches als Trigger fungieren soll. Abb. 6-1 zeigt ein Original und sein Trigger-Pendant:




Abbildung 6-1: Vergleich ohne/mit Trigger

Gemäß Abbildung 6-2 stimmen die vorhergesagten Label für die Standardemotionen näherungsweise mit denen aus dem Originallauf überein. Auf der anderen Seite werden die Trigger-Bilder zu 100% korrekt erkannt:




Abbildung 6-2: Konfusionsmatrix

Einen Angreifer wird das Ergebnis erfreuen, da augenscheinlich die normale Nutzung als Emotionsklassifizierer relativ unbeeinflusst bleibt. Durch den verdächtigen Spot noch dazu in zentraler Position könnte eine Attacke erkannt werden und missglücken. Zu Vergleichszwecken werden zwei weitere backdoor-poisoning-Angriffe getestet. Einmal wird das

Quadrat an einen unauffälligeren Spot, nämlich der oberen linken Bildecke, verschoben. Ein anderes Mal verkleinern wir es auf die Größe 2x2 (ausgefüllt mit Pixelwert 128), wiederum in der oberen linken Ecke. Die Resultate ergeben laut Abb. 6-3 folgendes Bild: das auffällige 3x3-Quadrat scheint selbst oben links in seiner Funktion als Trigger noch gut positioniert zu sein, während eine Verkleinerung an gleicher Stelle auf 2x2 einen Angreifer nicht mehr zum gewünschten Ziel führt.




Abbildung 6-3: Konfusionsmatrix weitere Testläufe

An dieser Stelle endet die Simulation. Es wurde gezeigt, welche negativen Folgen poisoning hervorruft und wie Trigger aus Angreifersicht gezielt bestimmte Vorhersagen auslösen können. Im nächsten Kapitel folgen eine kritische Reflektion und eine Vorstellung aktueller Forschungsfragen.

VII. REFLEKTION UND ZUKÜNFTIGE HERAUSFORDERUNGEN

Fortlaufend werden Forschungsergebnisse veröffentlicht über immer ausgefeiltere Angriffs- und Abwehrmechanismen. Mal sind es Publikationen, die demonstrieren „how to insert undetectable backdoors in model“ [Seite 1 bei 33], mal Studien im Bereich Large Language Models, wo z.B. so genannte *jailbreak attacks*, also das Generieren von "harmful, unethical, or otherwise objectionable content" [Seite 1 bei 34], dargestellt und auf Ihre Effizienz untersucht werden etwa mit Hilfe eines „set of 500 harmful behaviors formulated as instructions“ [Seite 9 bei 35]. Die Seite der Verteidigung versucht hybride Ansätze, die „uses more than one method to make a stronger defence system by playing to each one’s skills.“ [Seite 4 bei 36]. In Bewegung ist auch das Feld der standardisierten Evaluationsframeworks wie dem RobustBench [29] aus Kapitel 5, welche die Wirksamkeit von Angriffen oder die Effizienz des Schutzes zu messen versuchen.

Es findet ein regelrechtes Wettrüsten statt. Angesichts der ständig wachsenden Anzahl an Publikationen stehen heutige Survey-Arbeiten vor der unlösbaren Aufgabe den geltenden Forschungsstand vollständig zusammenzutragen. Im Anhang nachgereichte Abbildungen aus [37] illustrieren in Ausschnitten die erhebliche Vielfalt an Techniken, die bspw. schon für spezifische Angriffstypen wie Evasion-Attacken oder die im Rahmen dieser Arbeit nicht weiter behandelte

privacy protection entwickelt wurden. Besonders dank der visuellen Systematisierung dient das von [12] erstellte Übersichtswerk als gute Orientierungshilfe, obwohl es den Visualisierungen an Methoden der Verteidigung mangelt. Daraus könnte jedoch zukünftig ein Wegweiser bzw. eine Mindmap entstehen, so wie scikit-learn es in [38] für eine andere Problemstellung gelöst hat, wenn Schutzmaßnahmen exemplarisch für dazugehörige Angriffstechniken ergänzt würden.

Softwarehersteller wie der von Nessus, dem „mittlerweile beliebtesten Vulnerability-Scanner“ [Seite 344 ff. bei 39] tragen der aktuellen Entwicklung Rechnung und werben damit, dass Ihre Produkte „Prompt-Injektionen, Jailbreak-Versuche, Richtlinienverstöße und andere hochriskante Verhaltensweisen in KI-Plattformen“ [40] erkennen können. Ungeachtet der Versprechungen gilt jedoch immer noch: es gibt neben praktischen auch „Theoretical Limitations on Adversarial Robustness“ [Seite 56 bei 12]. Eine formale (mathematische) Sicherheitsprüfung könnte fallbezogen Gewissheit geben. Dieser Ansatz ist jedoch sehr aufwendig und daher noch nicht verbreitet.

Weitere Herausforderungen sind nach [Seite 38-40 bei 41]:

- Abwägung Schutz vs. Modellleistung
- Skalierbare, architekturunabhängige Verteidigung
- Ausbau domänenspezifischer Schutz

Die zukünftige Vorstellung innovativer Architekturmodelle wird Angreifern neue Pfade eröffnen, und Verteidiger werden zu wirksamen Lösungen gezwungen. An oberster Stelle und mit höchster Dringlichkeit gilt es somit standardisierte Evaluationstools zu entwickeln, mit denen eine möglichst große Bandbreite an KI-Systemen praktisch automatisiert auf Schwachstellen geprüft und auf Robustheit "zertifiziert" werden können, damit Zweifel an Zuverlässigkeit entkräftet und die Akzeptanz erhöht werden.

VIII. FAZIT

Adversariale Attacken sind nicht lediglich eine theoretische Gefahr. Das Forschungsfeld bleibt dynamisch. Während früher wie bei Goodfellow primär die Bilddomäne im Fokus stand, rücken zunehmend multimodale und sehr viel komplexere Modelle in den Fokus der Angreifer. Die Schutzmaßnahmen reichen von proaktiv über reaktiv. Einzelne Schutzmechanismen sind längst abgelöst von mehrschichtigen Verteidigungsmaßnahmen, da dies zur höheren Robustheit eines KI-Systems beitragen soll. Schon heute ist dies ein zentrales Qualitätsmerkmal von KI-Systemen, so dass ein tiefergehendes Verständnis über adversariale Attacken notwendig ist, denn „For AI systems to be considered trustworthy, they must meet several key characteristics, including being valid, reliable, safe, secure, resilient, accountable, transparent, explainable, interpretable, privacy-enhanced, and fair“ [Seite 209 bei 18].

LITERATURVERZEICHNIS

REFERENCES

- [1] Gillespie, N., Lockey, S., Curtis, et al., “Trust in artificial intelligence: A global study”, The University of Queensland and KPMG Australia, 2023. [Online]. Verfügbar: doi:10.14264/00d3c94
- [2] H. Thomson, ““Don’t ask what AI can do for us, ask what it is doing to us”: are ChatGPT and co harming human intelligence?”, The Guardian, 19.04.2025. [Online]. Verfügbar: <https://www.theguardian.com/technology/2025/apr/19/dont-ask-what-ai-can-do-for-us-ask-what-it-is-doing-to-us-are-chatgpt-and-co-harming-human-intelligence>. [Zugriff 08.11.2025]
- [3] MIT, “Your brain on ChatGPT”, 2025. [Online]. Verfügbar: <https://www.media.mit.edu/projects/your-brain-on-chatgpt/overview/>. [Zugriff 10.11.2025].
- [4] A. Chow, “ChatGPT may be eroding critical thinking skills, according to a New MIT study”, Time, 23.06.2025. [Online]. Verfügbar: <https://time.com/7295195/ai-chatgpt-google-learning-school/>. [Zugriff 10.11.2025]
- [5] Gerda Bortsova, Cristina González-Gonzalo, Suzanne C. Wetstein et al., “Adversarial attack vulnerability of medical image analysis systems: Unexplored factors”, in Medical Image Analysis 73 (2021). [Online]. Verfügbar: <https://www.sciencedirect.com/science/article/pii/S1361841521001870>
- [6] Amirhosein Chahe, Chenan Wang, Abhishek Jeyapratap et al., “Dynamic adversarial attacks on autonomous driving systems”, *arXiv preprint arXiv:2312.06701v1*, 2023
- [7] Sheilla Ann Bangoy Pacheco, Jheanel Espiritu Estrada, Mahesh M Goyani et al., “Hidden adversarial attack on facial biometrics - a comprehensive survey”, in Procedia Computer Science, vol. 258, pp. 1383-1390, 2025. [Online]. Verfügbar: <https://www.sciencedirect.com/science/article/pii/S1877050925014747>
- [8] Shuai Zhou, Chi Liu, Dayong Ye et al. “Adversarial attacks and defenses in deep learning: from a perspective of cybersecurity”, in ACM Computing Surveys, Volume 55, Issue 8, Artikel n° 163, pp. 1-39, 2022. [Online]. Verfügbar: <https://dl.acm.org/doi/10.1145/3547330>
- [9] Zhongliang Guo, Yifei, Qian, Yanli Li et al., “Beyond vulnerabilities: a survey of adversarial attacks as both threats and defenses in computer vision systems”, *arXiv preprint arXiv:2508.01845v1*, 2025
- [10] Junhao Dong, Junxi Chen, Xiaohua Xie et al., “Survey on adversarial attack and defense for medical image analysis: methods and challenges”, *arXiv preprint arXiv:2303.14133*, 2024
- [11] Matthew Jagielski; Alina Oprea; Battista Biggio et al., “Manipulating machine learning: poisoning attacks and countermeasures for regression learning”, in 2018 IEEE Symposium on Security and Privacy (SP), 2018. [Online]. Verfügbar: <https://ieeexplore.ieee.org/document/8418594>
- [12] Apostol Vassilev, Alina Oprea, Alie Fordyce et al., “Adversarial machine learning a taxonomy and terminology of attacks and mitigations”, in NIST Trustworthy and Responsible AI, März 2025. [Online]. Verfügbar: <https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-2e2025.pdf>
- [13] Sushil Jajodia, Pierangela Samarati, Moti Yung. “Encyclopedia of cryptography, security and privacy 3rd edition”. Springer, 2025
- [14] Christian Szegedy, Wojciech Zaremba, Ian Goodfellow et al., “Intriguing properties of neural networks”, *arXiv preprint arXiv:1312.6199*, 2024
- [15] Ian J. Goodfellow, Jonathon Shlens, Christian Szegedy et al., “Explaining and harnessing adversarial examples”, *arXiv preprint arXiv:1412.6572v3*, 2015
- [16] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza et al., “Generative adversarial nets”, *arXiv preprint arXiv:1406.2661*, 2014
- [17] Ian Goodfellow, “Lecture 16 | Adversarial examples and adversarial training”, Stanford University School of Engineering, 30.05.2017. [Online]. Verfügbar: https://www.youtube.com/watch?v=ClfsB_EYsVIlIst=PLqY9uEMecYpXC4sCrNRJ5uHwmTr3FpTui. [Zugriff 10.11.2025]
- [18] Dilli Prasad Sharma, Arash Habibi Lashkari, Mahdi Daghmehchi Firoozjaei et al. “Understanding AI in cybersecurity and secure AI - challenges, strategies and trends”. Springer, 2025
- [19] Palo Alto Networks, “What is the AI development lifecycle?”, Palo Alto, 2025. [Online]. Verfügbar: <https://www.paloaltonetworks.com/cyberpedia/ai-development-lifecycle/>. [Zugriff 13.11.2025]
- [20] Aurélien Géron. “Praxiseinstieg machine learning mit scikit-learn, Keras und TensorFlow”. O’Reilly, 2023
- [21] Tianyu Gui, Kang Lui, Brendan Dolan-Gavitt et al., “BadNets: evaluating backdooring attacks on deep neural networks”, in IEEE Access (Volume: 7), pp. 47230-47244, 18.04.2019. [Online]. Verfügbar: <https://ieeexplore.ieee.org/document/8685687>
- [22] Jeremy McHugh, Kristina Šekrst, Jon Cefalu et al., “Prompt injection 2.0: hybrid AI threats”, *arXiv preprint arXiv:2507.13169v1*, 2015
- [23] Mykita Mudryi, Markiy Chaklosh, Grzegorz Marcin Wojcik et al., “The hidden dangers of browsing AI agents”, *arXiv preprint arXiv:2505.13076*, 2025
- [24] Xiaowei Huang, Gaojie Jin, Wenjie Ruan, “Machine learning safety”. Springer, 2023
- [25] Divya Gopinath, Guy Katz, Corina S. Pasareanu et al., “DeepSafe: A Data-driven Approach for Checking Adversarial Robustness in Neural Networks”, *arXiv preprint arXiv:1710.00486*, 2017
- [26] Norbert Pohlmann. “Cyber-Sicherheit 2. Auflage”. Springer, 2022
- [27] Aneesh Sreevallabh Chivukula, Xinghao Yang, Bo Liu et al.. “Adversarial machine learning”. Springer, 2023
- [28] Amanda Berlin, Lee Brotherston, William F. Reyor III. “IT-Security - Der praktische Leitfaden”. O’Reilly, 2025
- [29] Francesco Croce, Maksym Andriushchenko, Vikash Sehwal et al., „RobustBench a standardized adversarial robustness”, *arXiv preprint arXiv:2010.09670*, 2021
- [30] Samith Chimmianan, “Human Face Emotions”, Kaggle, 2025. [Online]. Verfügbar: <https://www.kaggle.com/datasets/samithsachidanandan/human-face-emotions>. [Zugriff 10.11.2025]
- [31] GeeksForGeeks, “Emotion Detection Using Convolutional Neural Networks (CNNs)”, GeeksforGeeks, 23.07.2025. [Online]. Verfügbar: <https://www.geeksforgeeks.org/deep-learning/emotion-detection-using-convolutional-neural-networks-cnns/>. [Zugriff 13.11.2025]
- [32] Düzgün İlaslan, “Facial Emotion Recognition: A Deep Learning approach with Keras”, Medium, 06.08.2023. [Online]. Verfügbar: <https://medium.com/@ilaslanduzgun/facial-emotion-recognition-a-deep-learning-approach-with-keras-8e4fee7b7bb0>. [Zugriff 14.11.2025]
- [33] Shafi Goldwasser, Michael P. Kim, Vinod Vaikuntanathan et al., “Planting undetectable backdoors in machine learning models”, *arXiv preprint arXiv:2204.06974*, 2024
- [34] Patrick Chao, Edoardo Debenedetti Alexander Robey et al., “JailbreakBench: An open robustness benchmark for jailbreaking large language Models”, *arXiv preprint arXiv:2404.01318*, 2024
- [35] Andy Zou, Zifan Wang, Nicholas Carlini et al., “Universal and transferable adversarial attacks on aligned language models”, *arXiv preprint arXiv:2307.15043*, 2023
- [36] Satish Shankar Rao Banait, Anish C M., Madhumay Sen et al., “Advancements in defense mechanisms against adversarial attacks in computer vision”, in ICIMMI ’24: Proceedings of the 6th International Conference on Information Management & Machine Intelligence, Artikel n° 66, pp. 1-10, 02.09.2025. [Online]. Verfügbar: <https://dl.acm.org/doi/10.1145/3745812.3745886>
- [37] Sotiris Pelekis, Thanos Koutroubas, Afroditi Blika et al., “Adversarial machine learning: a review of methods, tools, and critical industry sectors”, Artificial Intelligence Review 58, 226 (2025). [Online]. Verfügbar: doi:10.1007/s10462-025-112147-4
- [38] scikit-learn developers, “Choosing the right estimator”, 2025. [Online]. Verfügbar: https://de.scikit-learn.org/stable/machine_learning_map.html. [Zugriff am 01.12.2025]
- [39] Eric Amberg, Daniel Schmid. “Hacking - Der umfassende Praxis-Guide 3. Auflage”. mitp, 2024
- [40] Tenable, “Tenable AI exposure”, 2025. [Online]. Verfügbar: <https://de.tenable.com/products/ai-exposure>. [Zugriff 13.11.2025]
- [41] Wencheng Yang, Song Wang, Di Wu et al., “Deep learning model inversion attacks and defenses: a comprehensive survey”, Artificial Intelligence Review 58, 242 (2025). [Online]. Verfügbar: doi:10.1007/s10462-025-11248-0

ANHANG

Dieser Teil soll Informationen nachreichen und oben Beschriebenes ergänzen.

Zu Kapitel IV - Klassifikation der Angriffsmethoden:

Abb. 4.1 auf Seite 3 zeigt die Taxonomie für generative KI-Modelle. Das Äquivalent für prädiktive KI-Modelle ist in Abbildung A-1 illustriert, entnommen von Seite 4 bei 12:




Abb. A-1: Taxonomie prädiktive KI

Zu Kapitel VI - Praxisfall:

Der Vollständigkeit halber ist in Abb. A-2 das für die Simulation von data poisoning und backdoor poisoning erstellte Keras-Modell veranschaulicht. Es ist an [31] angelehnt und unterscheidet sich hauptsächlich durch die Anzahl der Conv2D- und MaxPooling2D-Layer:

```
# Modellerstellung mit 5 Outputneuronen, d.h. 1 Ausgabe-Neuron pro Emotion

kerasmodel = tf.keras.Sequential()
kerasmodel.add(tf.keras.layers.Conv2D(filters=64, kernel_size=2, padding='same',
                                       activation='leaky_relu', input_shape=X_train[0].shape))
kerasmodel.add(tf.keras.layers.MaxPooling2D(pool_size=2))
kerasmodel.add(tf.keras.layers.Dropout(0.3))
kerasmodel.add(tf.keras.layers.Conv2D(filters=32, kernel_size=2,
                                       padding='same', activation='leaky_relu'))
kerasmodel.add(tf.keras.layers.MaxPooling2D(pool_size=2))
kerasmodel.add(tf.keras.layers.Dropout(0.3))
kerasmodel.add(tf.keras.layers.Flatten())
kerasmodel.add(tf.keras.layers.Dense(250, activation='leaky_relu'))
kerasmodel.add(tf.keras.layers.Dense(70, activation='leaky_relu'))
kerasmodel.add(tf.keras.layers.Dropout(0.5))
kerasmodel.add(tf.keras.layers.Dense(5, activation='softmax'))
```

Abb. A-2: Keras-Modell für Simulationen

Sonstiges:

Die im Artificial Review vol. 58 (2025) vorgestellte Publikation [37] präsentiert für ausgewählte Industriezweige wie autonomes Fahren zahlreiche Übersichten, welche eine Auswahl an state-of-the-art Attacken und Verteidigungsmethoden aus der Fachliteratur zusammentragen. Im Vergleich zu [12] mangelt es zwar an illustrativer Aufbereitung, dafür steigt die Arbeit thematisch für eine begrenzte Anzahl an Techniken sehr viel tiefer ins Detail.

1.) evasive Attacken

[Seite 14 bei 37] reiht ein ganzes Spektrum an state-of-the-art Evasion-Angriffen auf. Augenfällig ist der Umstand, dass es mittlerweile für jeden Wissensgrad (white/gray/black-box-Szenario) entwickelte Ansätze gibt:

Attack	Knowledge	Specificity	Perturbation	Scope	Learning
FGSM (Goodfellow et al. 2015)	White-box	Targeted	ℓ_∞	Imaging	One shot
L-BFGS (Szegedy et al. 2014)	White-box	Targeted	ℓ_∞	Imaging	One shot
BIM (Kurakin et al. 2017)	White-box	Untargeted	ℓ_∞	Imaging	Iterative
ILCM (Kurakin et al. 2017)	White-box	Targeted	ℓ_∞	Imaging	Iterative
PGD (Madry et al. 2018)	White-box	Targeted	ℓ_1, ℓ_∞	Imaging	Iterative
JSMA (Papernot et al. 2016a)	White-box	Targeted	ℓ_0	Imaging	Iterative
C&W (Carlini and Wagner 2017a)	White-box	Targeted, untargeted	$\ell_0, \ell_2, \ell_\infty$	Imaging	Iterative
DeepFool Moosavi-Dezfooli et al. 2016)	White-box	Untargeted	$\ell_1, \ell_2, \ell_\infty$	Imaging	Iterative
Universal Moosavi-Dezfooli et al. 2017)	White-box	Untargeted	ℓ_2, ℓ_∞	Universal	Iterative
EAD (Chen et al. 2018c)	White-box	Targeted, untargeted	ℓ_1	Imaging	Iterative
ZOO (Chen et al. 2017)	Black-box	Targeted, untargeted	ℓ_2	Imaging	Iterative
BA (Brendel et al. 2018)	Black-box	Targeted, untargeted	ℓ_2	Imaging	Iterative
HSJA (Chen et al. 2020b)	Black-box	Targeted, untargeted	ℓ_2, ℓ_∞	Imaging	Iterative
One-Pixel (Su et al. 2019)	Black-box	Targeted, untargeted	ℓ_0	Imaging	Iterative
UPSET (Sarkar et al. 2017)	Black-box	Targeted	ℓ_2, ℓ_∞	Universal	Iterative
ANGRI (Sarkar et al. 2017)	Black-box	Targeted	ℓ_2, ℓ_∞	Imaging	Iterative
Houdini (Cisse et al. 2017a)	Black-box	Targeted	ℓ_2, ℓ_∞	Imaging	Iterative
BAA-IQA (Ran et al. 2025)	Black-box	Targeted, untargeted	ℓ_2	Imaging	Iterative
AdvGAN (Xiao et al. 2018)	Gray-box, Black-box	Targeted	ℓ_2	Imaging	Iterative

Abb. A-3: Ausschnitt an evasive-attack-Techniken

2.) Verteidigungsmethoden im Bereich privacy protection

Anhand der in dieser Arbeit nicht weiter behandelten Thematik der privacy protection, also der Wahrung der Vertraulichkeit von Daten oder Modellen, spiegelt nachfolgende Abbildung [entnommen von Seite 28 bei 37] noch einmal sehr einprägsam die zwei grundlegenden Verteidigungsperspektiven wider, nämlich proaktiv oder reaktiv auf Bedrohungen zu antworten:

Defense	Objective	Approach	Details
Dataset Inference (Maini et al. 2021)	Reactive	UMI	Check specific training dataset
Conferrable AE (Lukas et al. 2021)	Reactive	UMI	Adversarial example fingerprint
Watermarking (Lederer et al. 2023)	Reactive	Watermarking	Embed hidden information
PRADA (Juuti et al. 2019)	Reactive	Detection-based	Distribution of queries analysis
DefenseNet (Yu et al. 2020)	Reactive	Detection-based	Adversarial example detection
SEAT (Zhang et al. 2021b)	Reactive	Detection-based	Adversarial example detection
Label-only return (Tramèr et al. 2016)	Proactive	Basic defense	Prediction API minimization
Well-formed queries (Kumar et al. 2019)	Proactive	Basic defense	Reject non-complete queries
Grad-CAM (Selvaraju et al. 2017)	Proactive	Input perturbations	Input noise to unimportant pixels
Confidence Rounding (Tramèr et al. 2016)	Proactive	Output perturbations	Confidence score rounding
BDPL (Zheng et al. 2019)	Proactive	DP	DP for decision boundary

Abb. A-4: Ausschnitt an privacy-protection-Techniken

3.) Autonomes Fahren - Angriffsmethoden

Abb. A-5 [entnommen von S. 51 bei 37] zeigt, welche Folgen heute schon erfolgreich provoziert werden können wie u.a. Fahrzeuge durch das Hinzufügen von Tarnmustern auf anderen Autos oder dem Schwärzen der Fahrbahnsuren zum Spurenwechsel zu bewegen oder einen Unfall herbeizuführen:

References	Knowledge	Target model	Attack type	Attack technique	Results
Zhou et al. (2020)	White-Box	E2E driving model	Evasion	Creation of adversarial billboards through optimization problem solving	Malfunction up to 23 degrees in the steering angle of the autonomous vehicle
Kong et al. (2020)	White-Box	E2E driving model	Evasion	Creation of adversarial billboards using GANs	Malfunction up to 19.17 degrees in the steering angle of the autonomous vehicle
Bolloor et al. (2020)	Black-Box	E2E driving model	Evasion	Designing black lanes on the road through Bayesian optimization method	Course change from right or left turn to straight in 25% of cases
Yang et al. (2021)	Black-Box	E2E driving model	Evasion	Designing black lanes on the road through gradient-based optimization method	Course change (right, left, straight) in more than 70% of cases
Bolloor et al. (2019)	White-Box	E2E driving model	Evasion	Designing black lanes on the road through parameterization of their shapes for optimal course change	Successful forced crash
Zhang et al. (2019c)	Black-Box	Object Detection	Evasion	Use of adversarial camouflage patterns on vehicles	Detection accuracy decreased by approximately 40%

Abb. A-5: Ausschnitt an Angriffsmethoden

4.) LLM-basierte NLP-Systeme

Abb. A-6 [entnommen S. 68 bei 37] zeigt wie hoch die Erfolgsrate (ASR = "attack success rate") für bestimmte Angriffe und Techniken auf ausgewählte Zielmodelle ist und unterstreicht nochmal, dass selbst state-of-the-art LLM-Modelle nicht vollständig immun vor Angriffen sind:

References	Knowledge	Target Model	Attack Type	Attack Technique	Results
Zou et al. (2023)	White-Box	Vicuna-7B	Privacy, Evasion (Prompt Injection)	GCG	Optimized on Vicuna, achieving 98% ASR
Zou et al. (2023)	Black-Box	GPT3.5-turbo-0301	Privacy, Evasion (Prompt Injection)	GCG	GCG ensemble optimized on Vicuna & Guanacos with 87.9% ASR
Zou et al. (2023)	Black-Box	GPT-4-0314	Privacy, Evasion (Prompt Injection)	GCG	GCG ensemble optimized on Vicuna & Guanacos with 46.9% ASR
Liu et al. (2024a)	White-Box	Vicuna-7B	Privacy, Evasion (Prompt Injection)	AutoDAN	HGA optimized on Vicuna, achieving 97% ASR
Liu et al. (2024a)	Black-Box	GPT-3.5-turbo-0301	Privacy, Evasion (Prompt Injection)	AutoDAN	HGA optimized on Vicuna, achieving 70% ASR
Chao et al. (2023)	Black-Box	GPT-3.5-turbo-1106	Privacy, Evasion (Prompt Injection)	PAIR	Transferred from GPT-4-0125-preview using Mixtral 8x7B Instruct, achieving 65% ASR
Qiang et al. (2024)	White-Box	LLaMA-7B	Poisoning	GBTL	1% poisoned samples on Alexa Massive dataset, achieving 80% PDR
Huang et al. (2024)	White-Box	LLaMA-7B	Poisoning	CBA	3% poisoned samples on Emotion dataset, achieving 100% ASR

Abb. A-6: Ausschnitt an Angriffsmethoden im Bereich LLM